

M4 — Instrumento Operacional

Folha de trabalho da investigação final

v2.1 — APROVADO E VIGENTE

Preencha este instrumento a partir do que foi observado no M16 v1.3.

1. Da evidência à questão experimental

Campo	Registro do grupo
Opção do grupo	P01_reclamacoes_assunto_v2.csv
Observação de origem no M16	Na validação (750 exemplos), a Representação A (unigramas, 336 atributos) teve acurácia 0.940 e F1-macro 0.938. A Representação B (unigramas+bigramas, 3449 atributos) teve 0.952 e 0.950. Houve 15 divergências A×B: em 12 o B corrigiu um erro do A e em 3 o B errou onde o A acertou. Houve ainda 33 erros comuns aos dois modelos. Os casos 871, 1111 e 1161 mostram textos com duas intenções (pagamento+produto, atendimento+entrega, entrega+produto).
Tipo de evidência	Divergência A×B
Hipótese ou expectativa	A inclusão de bigramas permite capturar o contexto local e expressões compostas, ajudando o modelo a desambiguar textos em que classes diferentes partilham o mesmo vocabulário.
Trilha escolhida	D
Questão escolhida ou adaptada	Em que tipos de texto a mudança de representação altera a previsão?
Justificativa com base no M16	A inspeção do M16 (ex: casos 871, 1111, 1161) revelou que as falhas e divergências ocorrem frequentemente em queixas com sobreposição de temas. Dado que a nossa abordagem utiliza TF-IDF + Classificador, um recurso focado em categorias apoiadas em sinais lexicais, a Trilha D justifica-se por testar como a expansão do contexto léxico (bigramas) ajuda na desambiguação. Crucialmente, a análise explicita o limite do problema: mesmo nos casos em que a

Campo	Registro do grupo
	representação B acerta a previsão, a presença de duas intenções válidas no texto demonstra que o modelo apenas coincidiu com a escolha prioritária do anotador, mantendo-se a limitação estrutural da classificação de rótulo único."

Antes de ampliar o corpus: confirme com o professor que sua trilha/questão não se sobrepõe à de outro grupo do mesmo corpus-base.

2. Planejamento da extensão

Campo	Registro do grupo
Quantidade de novos exemplos	120 novos exemplos, distribuídos entre as 5 classes do P01 (24 por classe).
Tipos de exemplos necessários	Por classe, 24 textos: 8 simples (uma intenção, linguagem comum), 4 curtos ou informais, 4 com negação (ex.: "não chegou"), 4 com dupla intenção unida por conector ("e", "além disso" ou "mas ao mesmo tempo") e 4 ambíguos (frase única, sem conector, que admite duas leituras plausíveis conforme a tabela de definições). No total: 40 simples, 20 curtos/informais, 20 com negação, 20 com dupla intenção e 20 ambíguos.
Origem/proveniência	Geração sintética suportada por Inteligência Artificial (LLM), utilizando os bilhetes do <i>corpus-base</i> original.
Critério de rotulagem	Aplicação de regra estrita baseada 5 categorias originais e textos de uma intenção são rotulados pelo problema descrito. Nos de dupla intenção, vale a regra fixa por conector: segunda intenção com "além disso" e primeira com "e" ou "mas ao mesmo tempo". Nas sobreposições, o desempate é: dinheiro (reembolso, estorno, cobrança) → pagamento; processo de devolver → troca_devolucao; defeito no item → produto; pedido de troca → troca_devolucao; dano causado pelo transporte → entrega; queixa sobre o suporte → atendimento. Rotulamos só o que o texto

Campo	Registro do grupo
	afirma, sem inferir culpa, fraude ou intenção. As regras foram fixadas antes de rodar os modelos.
Como tratar ambiguidades	Aplicar prioridade
Uso de IA, se houver	Para criação de 120 exemplos e para revisões

→ Manter a extensão separada do corpus-base bruto.

→ Evitar dados pessoais, sensíveis ou material sem autorização.

→ Congelar pergunta, preparação, representação, classificador e configuração antes de consultar o teste.

3. Resultado da investigação

Campo	Registro do grupo
Resultado na validação M3	Referência Majoritária (Classe "entrega"): Acurácia: 0.245 F1-macro: 0.079 Classificador Supervisionado (M15): Acurácia: 1.000 F1-macro: 1.000 2. Análise da Matriz de Confusão Padrão Observado: Todos os 49 exemplos da partição de validação estão na diagonal principal. Distribuição de Acertos: entrega (12), produto (11), pagamento (10), atendimento (9) e troca_devolucao (7). Interpretação: O modelo atingiu separação perfeita das classes nesta amostra, zerando as células de falsos positivos e falsos negativos e superando com ampla margem a regra majoritária.
Resultado no teste final	Configuração final: B — TF-IDF unigramas + bigramas (1,2) Acurácia no teste: 0.956 F1-macro no teste: 0.955 Número de erros no teste: 33 Resultado observado: O modelo alcançou acurácia de 0.956 e F1-macro de 0.955 no teste final, mas os erros remanescentes concentraram-se fortemente em temas que frequentemente se sobrepõem no mundo real. Interpretação: O caso 300 ilustra perfeitamente o desafio de textos com múltiplas intenções, onde o cliente relata simultaneamente um problema de 'pagamento' (valor incorreto da parcela) e de 'produto' (falta de acessório). Isso demonstra que o modelo lida bem com a maior parte dos dados, mas esbarra na limitação de atribuir rótulos únicos a reclamações tão complexas. Questão experimental respondida: O comportamento do sistema muda quando a representação inclui combinações locais de duas

Campo	Registro do grupo
	palavras? conclusao: inconclusiva — JUSTIFICAR: O próprio documento afirma que "Esse resultado ainda não permite concluir que a utilização de bigramas seja a solução definitiva para todos os problemas de classificação". Embora tenha havido uma ligeira melhoria nas métricas, as ambiguidades estruturais da linguagem e os textos com múltiplas intenções "criam um teto de desempenho que não é resolvido apenas pelo aumento do espaço vetorial". Portanto, o uso de bigramas não é suficiente para concluirmos que o problema da ambiguidade foi totalmente superado. Limitação principal: As ambiguidades estruturais e as mensagens com múltiplas intenções impõem um limite natural ao desempenho do modelo, reforçando a limitação técnica de se utilizar rótulos únicos para problemas que se sobrepõem.
Resultado na extensão/conjunto de desafio	configuracao_final: B — TF-IDF unigramas + bigramas (1,2) acuracia_teste: 0.954 f1_macro_teste: 0.953 numero_erros_teste: 35 resultado_observado: O modelo manteve um alto desempenho na partição de teste inédita, alcançando acurácia de 0.954 e F1-macro de 0.953, com o registro de 35 erros em 768 casos avaliados. interpretacao: Embora a inclusão de bigramas tenha capturado melhor o contexto adjacente em algumas situações, os erros remanescentes demonstram que textos com queixas simultâneas continuam a confundir o modelo, indicando que a expansão dimensional tem limites práticos na desambiguação de intenções complexas. questao_experimental_respondida: Sim, a métrica de acurácia foi numericamente superior ao modelo base, respondendo à questão, mas a análise qualitativa demonstra que a alteração da representação não resolve os problemas mais

Campo	Registro do grupo
	profundos de sobreposição semântica. conclusao: inconclusiva — JUSTIFICAR: O próprio documento afirma que "Esse resultado ainda não permite concluir que a utilização de bigramas seja a solução definitiva para todos os problemas de classificação". Embora tenha havido uma ligeira melhoria nas métricas, as ambiguidades estruturais da linguagem e os textos com múltiplas intenções "criam um teto de desempenho que não é resolvido apenas pelo aumento do espaço vetorial". Portanto, o uso de bigramas não é suficiente para concluirmos que o problema da ambiguidade foi totalmente superado. limitacao_principal: A representação TF-IDF combinada a um classificador tradicional é incapaz de processar e priorizar narrativas com múltiplas intenções explícitas (múltiplas queixas na mesma frase), exigindo uma abordagem multilabel para ultrapassar o teto de desempenho atual.
Principal erro ou caso difícil	Principal erro ou caso difícil: Texto (Índice 300): "A parcela veio com valor incorreto, mas ao mesmo tempo faltou um acessório dentro da caixa." Classe Real: pagamento Classe Prevista: produto Interpretação do caso: Este erro representa a limitação estrutural do modelo frente a narrativas com múltiplas queixas simultâneas. O texto contém vocabulário explícito e forte para duas categorias distintas: termos de pagamento ("parcela", "valor incorreto") e termos de produto ("faltou um acessório", "caixa"). Como a arquitetura do classificador força a escolha de apenas um rótulo final (classificação multiclasse tradicional), ele é incapaz de hierarquizar ou classificar o texto adequadamente como um problema duplo, gerando um erro inevitável que a simples adição de bigramas não consegue resolver.

Campo	Registro do grupo
O que mudou?	Com a adição de 120 novos textos, verificou-se uma ligeira queda nas métricas: a acurácia desceu de 0.956 para 0.954 e o F1-macro de 0.955 para 0.953, enquanto o número de erros subiu de 33 para 35.
A questão experimental foi respondida?	Sim. A adição de bigramas superou numericamente o modelo base, contudo, a análise qualitativa revelou que esta alteração não é suficiente para resolver a sobreposição semântica em textos com queixas simultâneas.
Conclusão	Inconclusiva. Embora exista uma melhoria, as ambiguidades estruturais da linguagem e os textos com múltiplas intenções criam um limite de desempenho que o aumento do espaço vetorial (bigramas) não consegue ultrapassar sozinho.
Limitação principal	A representação TF-IDF combinada com um classificador tradicional de rótulo único é incapaz de processar narrativas com múltiplas intenções explícitas na mesma frase, sendo necessária uma abordagem de classificação <i>multilabel</i> .

4. O que entregar em 03/10

- Este Instrumento M4 preenchido.
- Notebook final executável com a investigação M4 incorporada.
- Corpus final com extensão própria documentada.
- README final com pergunta, arquivos, execução, resultados, limites e uso de IA.

Não entregar relatório técnico separado. A apresentação será usada em 06/10 para a defesa.

5. Checklist final

- corpus-base bruto preservado
- extensão com pelo menos 80 exemplos e proveniência registrada
- trilha e questão justificadas por evidência do M16
- teste usado somente depois de congeladas as decisões
- nenhum ajuste feito depois de observar o teste
- acurácia, F1-macro, matriz e casos difíceis interpretados

→ conclusão responde à questão e registra limites

→ README, notebook, corpus e Instrumento M4 coerentes entre si